

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



CƠ SỞ TRÍ TUỆ NHÂN TẠO
FUTOSHIKI

Giải bài toán bằng Logic vị từ bậc nhất và các thuật toán suy diễn

Giảng viên hướng dẫn: Thầy Lê Ngọc Thành
Thầy Huỳnh Lâm Hải Đăng
Thầy Lê Nhựt Nam

Sinh viên thực hiện:

Họ và tên	Mã số sinh viên	Lớp
Nguyễn Nhựt Huy	24127398	24C11
Trần Quang Minh Huy	24127403	24C11
Trịnh Khánh Linh	24127437	24C11
Nguyễn Minh Khôi	24127066	24C11

TP. Hồ Chí Minh, tháng 2/2026

THÔNG TIN VỀ ĐỒ ÁN

Mã học phần: CSC14003

Tên học phần: Cơ sở trí tuệ nhân tạo

Tên đồ án: Futoshiki (Giải bài toán bằng Logic vị từ bậc nhất và các thuật toán suy diễn)

Hình thức: Bài tập nhóm

Giảng viên: thầy Lê Ngọc Thành, thầy Huỳnh Lâm Hải Đăng, thầy Lê Nhựt Nam

Sinh viên thực hiện:

Nguyễn Nhựt Huy 24127398

Trần Quang Minh Huy 24127403

Trịnh Khánh Linh 24127437

Nguyễn Minh Khôi 24127066

Mục lục

Danh sách bảng	1
Danh sách thuật toán	2
1 Phân công công việc	3
1.1 Phân công chi tiết	3
1.2 Yêu cầu đồ án	4
2 Các yếu tố ảnh hưởng đến mức độ Overfitting	5
2.1 Nhóm các yếu tố về dữ liệu (data-driven factors)	5
2.1.1 Số lượng dữ liệu huấn luyện	5
2.1.2 Hiện tượng học nhiều và sự nhạy cảm của thuật toán	6
2.1.3 Tỷ lệ đặc trưng trên mẫu (Feature-to-Sample Ratio – p/n)	7
2.2 Nhóm các yếu tố về mô hình (model-driven factors)	7
2.2.1 Sự nhạy cảm với sai lệch và độ phức tạp mô hình	7
2.2.2 Ngưỡng nội suy và góc nhìn hiện đại (Double Descent)	8
2.2.3 Bản chất của Maximum Likelihood (MLE) và cách tiếp cận Bayesian	8
2.3 Nhóm yếu tố về quy trình và thuật toán	9
2.3.1 Sự hiện diện của các điểm dị biệt (Outliers)	9
Tài liệu tham khảo	10

Danh sách bảng

1.1

Phân công công việc các thành viên

3

1.2

Bảng tự đánh giá yêu cầu bắt buộc

4

Danh sách thuật toán

Phần 1

Phân công công việc

1.1 Phân công chi tiết

Bảng 1.1: Phân công công việc các thành viên

Thành viên	Công việc được giao	Hoàn thành
Nguyễn Nhật Huy	• Quản lý repository nhóm • Cài đặt ground KB • Cài đặt thuật toán Forward Chaining • Cài đặt truy vấn Backward Chaining • Rà soát, chỉnh sửa lỗi và hoàn thiện nội dung báo cáo; bổ sung các phần còn thiếu và chuẩn hóa định dạng. • Thiết kế, cài đặt GUI và visualize quá trình chạy các thuật toán	100%
Trần Quang Minh Huy	• Cài đặt thuật toán Brute-force + Backtracking • Edit video demo • Hỗ trợ các công việc chung của nhóm như chuẩn bị dữ liệu, kiểm tra kết quả và viết file README hướng dẫn chạy chương trình.	100%
Trịnh Khánh Linh	• Biểu diễn FOL + Skolem + CNF • Viết báo cáo Forward Chaining, Backward Chaining, kết quả thực nghiệm • Quay video demo	100%
Nguyễn Minh Khôi	• Cài đặt thuật toán A* + heuristic • Viết báo cáo heuristic của A* • Viết báo cáo benchmark	100%

1.2 Yêu cầu đồ án

Bảng 1.2: Bảng tự đánh giá yêu cầu bắt buộc

STT	Yêu cầu	Trạng thái	Ghi chú
1	Hình thức hóa FOL đầy đủ	Hoàn thành	Dạng Skolem & CNF cho ≥ 3 tiên đề
2	Sinh ground KB tự động theo N	Hoàn thành	Theo dạng chuẩn CNF
3	Implement Forward Chain-ing	Hoàn thành	Viết từ đầu, đúng trên mọi test case
4	Implement Backward Chain-ing	Hoàn thành	Kiểu Prolog, truy vấn Val(i,j,?)
5	Implement A* Search	Hoàn thành	Heuristic chấp nhận được, có phân tích & so sánh
6	Implement Brute-force & Backtracking	Hoàn thành	Dùng để so sánh hiệu năng
7	Thiết kế ≥ 10 file input	Hoàn thành	Đa dạng kích thước: 4x4, 5x5, 6x6, 7x7, 9x9
8	Báo cáo đầy đủ	Hoàn thành	FOL, pseudocode, thực nghiệm (bảng + biểu đồ), so sánh thuật toán
9	Video demo	Hoàn thành	≥ 3 test case, upload YouTube/-Drive
10	Nộp đúng cấu trúc .zip	Hoàn thành	Docs/, Source/, README.txt, requirements.txt

Phần 2

Các yếu tố ảnh hưởng đến mức độ Overfitting

2.1 Nhóm các yếu tố về dữ liệu (data-driven factors)

2.1.1 Số lượng dữ liệu huấn luyện

2.1.1.1 Ảnh hưởng của kích thước mẫu nhỏ

Sự ghi nhớ thay vì học quy luật Khi kích thước tập huấn luyện nhỏ, mô hình thường đạt độ chính xác rất cao trên dữ liệu huấn luyện nhưng suy giảm mạnh trên tập kiểm tra. Nguyên nhân là do mô hình có xu hướng ghi nhớ cả nhiễu trong dữ liệu thay vì học các quy luật tổng quát, dẫn đến overfitting [1].

Hệ quả Trong các lĩnh vực như neuroimaging hay genomics, nơi số đặc trưng lớn nhưng số mẫu hạn chế, các nghiên cứu thường báo cáo độ chính xác cao bất thường [2]. Thực nghiệm cho thấy tồn tại mối tương quan nghịch giữa kích thước mẫu và độ chính xác, ví dụ với hệ số $r = -0.70$, cho thấy phần lớn biến thiên về độ chính xác có thể bị chi phối bởi quy mô dữ liệu.

Điều này phản ánh hiện tượng sai số lạc quan (optimistic bias), khi mô hình khớp với nhiễu trong dữ liệu nhỏ thay vì học được cấu trúc thực sự.

2.1.1.2 Mối liên hệ giữa N và độ phức tạp

Trong cuốn sách *Pattern Recognition and Machine Learning*, [3, pp. 4–9] đã sử dụng ví dụ về khớp đường cong đa thức (Polynomial Curve Fitting) để minh họa mối liên hệ giữa số lượng dữ liệu N và độ phức tạp của mô hình M .


Thiết lập bài toán Xét một tập dữ liệu gồm N quan sát (x, t) , trong đó t được sinh từ hàm $\sin(2\pi x)$ kết hợp với nhiễu Gaussian. Mô hình sử dụng là đa thức bậc M :

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M = \sum_{j=0}^M w_jx^j$$


Các tham số $\mathbf{w}$ được ước lượng bằng cách tối thiểu hóa sai số bình phương.

$$E(w) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, w) - t_n\}^2$$

Ảnh hưởng của N đến overfitting Như thể hiện trong Hình 2.1, khi số lượng dữ liệu nhỏ (ví dụ $N = 10$) và sử dụng đa thức bậc cao ($M = 9$), mô hình có thể khớp hoàn toàn dữ liệu huấn luyện nhưng dao động mạnh giữa các điểm, dẫn đến khả năng tổng quát hóa kém. Ngược lại, trong Hình 2.2, khi tăng số lượng dữ liệu (ví dụ $N = 100$), với cùng một giá trị M , hiện tượng overfitting giảm đáng kể do các ràng buộc từ dữ liệu trở nên mạnh hơn, hạn chế khả năng mô hình khớp với nhiễu.



Hình 2.1: Mô hình so với đường dữ liệu thật ở kích thước dữ liệu nhỏ



Hình 2.2: Mô hình so với đường dữ liệu thật ở kích thước dữ liệu lớn

Kết luận Tập dữ liệu càng lớn thì mô hình càng có khả năng sử dụng các cấu trúc phức tạp mà vẫn duy trì khả năng tổng quát hóa. Một quy tắc kinh nghiệm là số lượng dữ liệu nên lớn hơn nhiều lần số tham số của mô hình. Tuy nhiên, trong cách tiếp cận Bayesian, điều này có thể được nói lỏng nhờ cơ chế điều chuẩn tự động.

2.1.2 Hiện tượng học nhiễu và sự nhạy cảm của thuật toán

Trong môi trường lý tưởng, các mô hình học máy được kỳ vọng sẽ tìm ra các quy luật tổng quát (disciplines) ẩn sau dữ liệu huấn luyện. Tuy nhiên, trên thực tế, dữ liệu luôn bị bao phủ bởi một lớp “nhiều” phát sinh từ các quá trình ngẫu nhiên hoặc các nguồn biến thiên không thể quan sát được.

2.1.2.1 Bản chất của hiện tượng học nhiễu (Noise Learning)

Học nhiễu xảy ra khi mô hình học cả những biến động ngẫu nhiên trong dữ liệu thay vì chỉ nắm bắt cấu trúc tổng quát[1].

- **Nhầm lẫn giữa tín hiệu và nhiễu.** Mô hình không phân biệt được đâu là quy luật thực và đâu là sai số ngẫu nhiên, đặc biệt khi dữ liệu chứa nhiều biến động nhỏ.
- **Hệ quả lên khả năng tổng quát hóa.** Việc khớp với nhiễu làm mô hình trở nên thiếu ổn định, dẫn đến sai số kiểm tra cao dù sai số huấn luyện thấp. [4, p. 221]

2.1.2.2 Các yếu tố thực nghiệm làm trầm trọng hiện tượng học nhiễu

- **Sai lầm trong quy trình kiểm chứng.** Việc chọn đặc trưng hoặc tối ưu tham số trên toàn bộ dữ liệu trước khi chia tập kiểm tra gây rò rỉ thông tin và làm sai lệch đánh giá[4, p. 245].

- **Quá trình tối ưu quá mức.** Huấn luyện quá lâu hoặc không có điều chuẩn (regularization) khiến mô hình dần khớp với nhiễu trong dữ liệu.

2.1.3 Tỷ lệ đặc trưng trên mẫu (Feature-to-Sample Ratio – p/n)

Tỷ lệ p/n phản ánh mối quan hệ giữa độ phức tạp biểu diễn và lượng thông tin quan sát, và có thể được xem là hệ quả trực tiếp của lời nguyền chiều dữ liệu.

Lời nguyền chiều dữ liệu (Curse of Dimensionality) Khi số lượng đặc trưng tăng lên, không gian đầu vào mở rộng theo hàm mũ, dẫn đến hiện tượng dữ liệu trở nên thưa thớt [3, pp. 33-38].

- **Sự bùng nổ của không gian.** Nếu mỗi chiều được chia thành M phần, thì trong không gian D chiều sẽ có M^D vùng. Do đó, số lượng dữ liệu cần thiết để bao phủ không gian này tăng theo hàm mũ, gây khó khăn cho việc ước lượng đáng tin cậy.
- **Mật độ lấy mẫu giảm mạnh.** Mật độ lấy mẫu hiệu quả giảm nhanh khi số chiều tăng, khiến khoảng cách trung bình giữa các điểm dữ liệu tăng lên đáng kể. Để đạt mật độ tương đương với 100 điểm trong không gian một chiều, không gian 10 chiều sẽ cần tới 100^{10} điểm, vượt xa khả năng thu thập dữ liệu thực tế [4, p. 23].

Sự thưa thớt và vấn đề ở biên không gian Trong không gian nhiều chiều, phần lớn các điểm dữ liệu có xu hướng nằm gần biên của không gian mẫu [4, p. 23].

- **Lân cận mất tính cục bộ.** Để thu thập một tỷ lệ nhỏ dữ liệu (ví dụ 10%) trong không gian 10 chiều, cần bao phủ tới khoảng 80% phạm vi của mỗi biến. Khi đó, khái niệm “lân cận” không còn mang tính cục bộ, làm giảm hiệu quả của các phương pháp dựa trên khoảng cách [4, p. 22].
- **Ngoại suy thay vì nội suy.** Do dữ liệu tập trung ở biên, việc dự đoán cho điểm mới thường yêu cầu mô hình thực hiện ngoại suy (extrapolation), vốn tiềm ẩn rủi ro cao và dễ dẫn đến sai số lớn, đặc biệt khi mô hình đã khớp với nhiễu[4, p. 23]..

Nguy cơ xuất hiện các “quy luật giả” Tỷ lệ p/n cao cung cấp cho mô hình nhiều bậc tự do, làm tăng khả năng xuất hiện các tương quan ngẫu nhiên.

- **Khớp với tổ hợp nhiễu.** Khi số lượng đặc trưng vượt xa số lượng mẫu, mô hình dễ tìm ra các tổ hợp đặc trưng có vẻ giải thích tốt dữ liệu, nhưng thực chất chỉ là khớp với nhiễu [2, pp. 1, 3].
- **Sai lệch từ quy trình chọn lọc.** Nếu việc lựa chọn đặc trưng được thực hiện trên toàn bộ dữ liệu trước khi tách tập kiểm chứng, mô hình có thể tận dụng các tương quan ngẫu nhiên để đạt độ chính xác cao giả tạo, nhưng sẽ thất bại trên dữ liệu thực [2, p. 2, 12].
- **Ảnh hưởng của quy mô mẫu.** Trong các tập dữ liệu nhỏ với số đặc trưng lớn, một phần đáng kể biến thiên của độ chính xác có thể bị chi phối bởi chính kích thước mẫu thay vì chất lượng mô hình[2, p. 7].

2.2 Nhóm các yếu tố về mô hình (model-driven factors)

2.2.1 Sự nhạy cảm với sai lệch và độ phức tạp mô hình

Mức độ overfitting phụ thuộc chặt chẽ vào khả năng của mô hình trong việc phân biệt giữa dữ liệu đại diện và nhiễu.

- **Tác động của độ linh hoạt.** Các mô hình có độ phức tạp cao (ví dụ: đa thức bậc cao hoặc mạng thần kinh lớn) có nhiều bậc tự do, khiến chúng trở nên cực kỳ nhạy với các dao động nhỏ trong dữ liệu. Thay vì học một hàm trơn biểu diễn quy luật thực, mô hình có thể dao động mạnh để khớp chính xác các điểm nhiễu[3, pp. 4–12].
- **Sự đánh đổi Bias–Variance.** Dưới góc nhìn thống kê, sự nhạy cảm này làm tăng thành phần phương sai (variance) của mô hình. Một mô hình có phương sai cao sẽ thay đổi đáng kể dự đoán khi dữ liệu huấn luyện thay đổi nhẹ, phản ánh sự thiếu ổn định trước nhiễu.[5]

2.2.2 Ngưỡng nội suy và góc nhìn hiện đại (Double Descent)

Theo quan điểm cổ điển, mức độ overfitting tăng dần khi tỷ lệ p/n tăng. Tuy nhiên, các nghiên cứu gần đây đã phát hiện một hiện tượng mới được gọi là *double descent* [6].

- **Đỉnh overfitting tại ngưỡng nội suy.** Hiện tượng quá khớp đạt mức nghiêm trọng nhất tại ngưỡng nội suy, khi số lượng tham số xấp xỉ số lượng mẫu ($p \approx n$).
- **Cải thiện trong chế độ overparameterized.** Khi số lượng tham số vượt xa số lượng mẫu ($p \gg n$), sai số kiểm tra có thể giảm trở lại. Điều này được giải thích bởi việc các thuật toán tối ưu (như SGD) có xu hướng tìm được nghiệm có chuẩn nhỏ và trơn hơn, từ đó cải thiện khả năng khái quát hóa [7].

2.2.3 Bản chất của Maximum Likelihood (MLE) và cách tiếp cận Bayesian

1. Bản chất của Maximum Likelihood (MLE) và nguy cơ Overfitting

Phương pháp Maximum Likelihood Estimation (MLE) tìm kiếm một ước lượng điểm (point estimate) cho các tham số sao cho xác suất thu được tập dữ liệu quan sát là lớn nhất. Tuy nhiên, cách tiếp cận này đối mặt với các vấn đề sau:

- **Tối ưu hóa cục bộ trên dữ liệu huấn luyện:** MLE giả định rằng các giá trị tham số làm cho dữ liệu huấn luyện có xác suất cao nhất chính là các giá trị thực tế. Điều này khiến mô hình cực kỳ nhạy cảm với nhiễu ngẫu nhiên trong tập dữ liệu nhỏ. Ví dụ, trong bài toán khớp đường cong bằng đa thức, MLE có thể chọn các trọng số cực lớn để đi qua chính xác mọi điểm dữ liệu, dẫn đến những dao động dữ dội (wild oscillations) và khả năng khái quát hóa kém.
- **Sai lệch hệ thống (Bias) trong ước lượng:** Một ví dụ điển hình là việc ước lượng phương sai của phân phối Gaussian. MLE có xu hướng đánh giá thấp (underestimate) phương sai thực tế vì nó đo lường sự biến thiên dựa trên trung bình mẫu (vốn đã được điều chỉnh theo nhiễu của dữ liệu huấn luyện) thay vì trung bình thực của quần thể.
- **Vấn đề với dữ liệu phân tách hoàn hảo:** Trong các mô hình phân loại như Logistic Regression, nếu dữ liệu có thể phân tách tuyến tính một cách hoàn hảo, MLE sẽ đẩy các tham số tiến tới vô cùng để ép xác suất dự báo về 1 hoặc 0, dẫn đến mô hình bị quá khớp nghiêm trọng.

2. Cách tiếp cận Bayesian và sức mạnh của sự tích phân (Marginalization)

Ngược lại với ước lượng điểm, phương pháp Bayesian không tìm một giá trị tham số duy nhất mà duy trì một phân phối xác suất (posterior distribution) trên toàn bộ không gian tham số.

- **Nguyên lý tích phân (Marginalization):** Thay vì đưa ra dự báo dựa trên một bộ tham số tốt nhất, phương pháp Bayesian sử dụng phân phối dự báo (predictive distribution) bằng cách lấy trung bình có trọng số của tất cả các cấu hình tham số khả thi thông qua phép tích phân. Điều này giúp tính toán đến sự không chắc chắn của tham số (parameter uncertainty).

- **Tự động điều chỉnh độ phức tạp (Occam’s Razor):** Trong khung tham chiếu Bayesian (đặc biệt là thông qua Model Evidence hoặc Marginal Likelihood), các mô hình quá phức tạp sẽ bị phạt một cách tự nhiên. Một mô hình quá linh hoạt (quá nhiều tham số) sẽ phân tán xác suất của nó trên quá nhiều tập dữ liệu có thể, dẫn đến việc xác suất cho tập dữ liệu thực tế bị giảm xuống. Do đó, phương pháp Bayesian thường ưu tiên các mô hình có độ phức tạp trung bình — đủ tốt để giải thích dữ liệu nhưng đủ đơn giản để không khớp với nhiễu.
- **Số lượng tham số hiệu dụng:** Trong mô hình Bayesian, số lượng tham số tham gia thực sự vào việc khớp dữ liệu (effective number of parameters) sẽ tự động điều chỉnh dựa trên kích thước của tập dữ liệu, giúp tránh việc mô hình quá phức tạp so với lượng thông tin hiện có.

2.3 Nhóm yếu tố về quy trình và thuật toán

2.3.1 Sự hiện diện của các điểm dị biệt (Outliers)

Các điểm dị biệt là những quan sát không tuân theo phân phối chung của dữ liệu hoặc nằm xa ranh giới quyết định lý tưởng. Sự hiện diện của chúng trong tập huấn luyện là một trong những tác nhân quan trọng dẫn đến overfitting, đặc biệt đối với các mô hình dựa trên các giả định thống kê cứng nhắc.

Cơ chế kéo lệch mô hình (Model Pulling) Hiện tượng mô hình bị “kéo lệch” xuất phát từ bản chất của các hàm mất mát phổ biến

- **Sự nhạy cảm của bình phương tối thiểu (Least Squares).** Phương pháp bình phương tối thiểu thiếu tính bền vững (robustness) trước các điểm dị biệt. Do hàm mất mát sử dụng bình phương sai số, các quan sát có sai số lớn sẽ có ảnh hưởng rất mạnh đến quá trình tối ưu[3, p. 185].
- **Mối liên hệ với phân phối Gaussian.** Việc sử dụng bình phương tối thiểu tương đương với ước lượng hợp lý cực đại (Maximum Likelihood) dưới giả định nhiễu tuân theo phân phối Gaussian. Do phân phối này có “đuôi nhẹ”, nó không mô hình hóa tốt các điểm nằm xa trung tâm, khiến tham số ước lượng bị lệch đáng kể khi xuất hiện outliers[3, p. 29, 103].

Tác động đến ranh giới quyết định Để giảm sai số huấn luyện, mô hình sẽ cố gắng điều chỉnh tham số nhằm khớp với cả các điểm dị biệt:

- **Điều chỉnh cực đoan.** Ranh giới quyết định có thể bị dịch chuyển hoặc biến dạng mạnh để bao phủ các điểm nằm xa, ngay cả khi chúng chỉ là nhiễu. Ví dụ, trong bài toán phân loại tuyến tính, một vài điểm dị biệt có thể làm thay đổi đáng kể hướng của siêu phẳng quyết định[3, pp. 185-186].
- **Mất khả năng khái quát hóa.** Khi ranh giới bị kéo lệch theo các điểm dị biệt, mô hình không còn phản ánh đúng quy luật của phần lớn dữ liệu. Điều này dẫn đến sai số huấn luyện thấp nhưng sai số kiểm tra cao[4, p. 112].

Điểm khác biệt quan trọng của outliers so với nhiễu thông thường là ảnh hưởng không cân xứng của chúng lên hàm mất mát, đặc biệt trong các phương pháp sử dụng bình phương sai số. Điều này khiến chỉ một số ít quan sát cũng có thể làm thay đổi đáng kể tham số mô hình.

Tài liệu tham khảo

[1] Xue Ying. “An Overview of Overfitting and its Solutions”. *Journal of Physics: Conference Series* 1168 (2019), 022022. DOI: [10.1088/1742-6596/1168/2/022022](https://doi.org/10.1088/1742-6596/1168/2/022022).

[2] Andrius Vabalas **and others**. “Machine learning algorithm validation with a limited sample size”. *PLoS ONE* 14.11 (2019), e0224365. DOI: [10.1371/journal.pone.0224365](https://doi.org/10.1371/journal.pone.0224365).

[3] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.

[4] Trevor Hastie, Robert Tibshirani **and** Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2 **edition**. Springer, 2009.

[5] Gilad Dar, Vidya Muthukumar **and** Richard G. Baraniuk. “Interpolating Classifiers Make Few Mistakes”. *arXiv preprint arXiv:2109.02355* (2021). DOI: [10.48550/arXiv.2109.02355](https://doi.org/10.48550/arXiv.2109.02355).

[6] <tên tác giả>. “<tên bài báo>”. *arXiv preprint* (2021). DOI: [10.48550/arXiv.2109.02355](https://doi.org/10.48550/arXiv.2109.02355).

[7] Mikhail Belkin **and others**. “Reconciling modern machine-learning practice and the classical bias-variance trade-off”. *Proceedings of the National Academy of Sciences* (2019). DOI: [10.1073/pnas.1903070116](https://doi.org/10.1073/pnas.1903070116).